

Sveučilište Jurja Dobrile u Puli

Fakultet Informatike u Puli

Roko Fumić

**Predviđanje cijena nafte koristeći Monte  
Carlo simulacije**

**Projekt**

Kolegij - Modeliranje i simulacije

Nositelj - Izv. prof. dr. sc. Darko Etinger

Asistent - Robert Šajina, mag. inf.

Pula, Lipanj 2022.

<b>Uvod</b>	<b>2</b>
<b>Podaci</b>	<b>2</b>
<b>Konceptualni model</b>	<b>3</b>
<b>Računalni model</b>	<b>4</b>
<b>Zaključak</b>	<b>7</b>
<b>Popis literature</b>	<b>8</b>

## Uvod

Monte Carlo simulacija je metoda za modeliranje vjerojatnosti određenog ishoda u nekom sustavu koja neizvjesnim varijablama sustava dodjeljuje vrijednosti iz razdioba slučajnih varijabli (Čerić, 1993). Izračunom prosjeka nasumičnih vrijednosti iz velikog broja simulacija dobiva se procjena vrijednosti neizvjesne varijable.

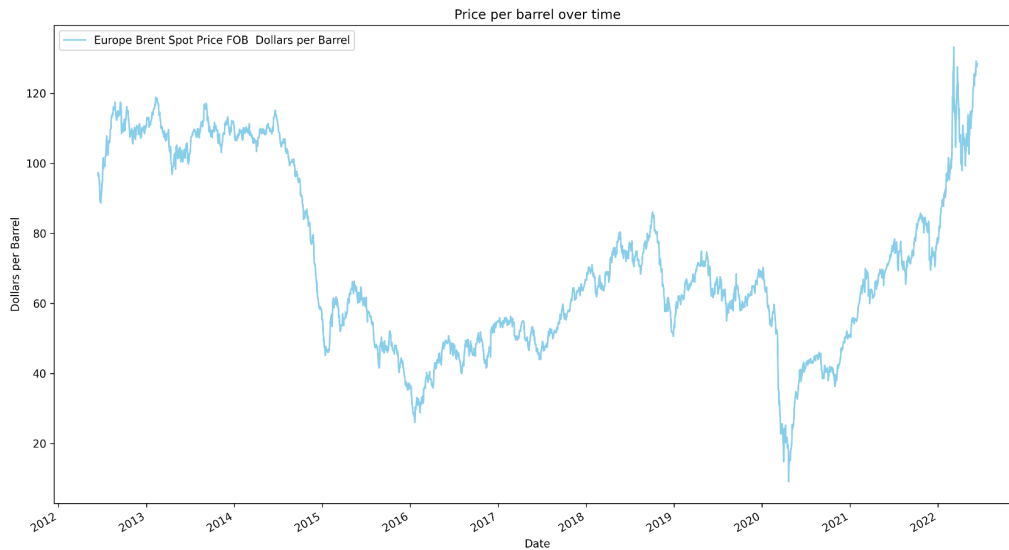
U ovom radu opisuje se proces izrade simulacijskog modela za procjenu budućih cijena nafte Monte Carlo metodom koristeći povijesne podatke iz razdoblja od 2012. do 2022. godine .

## Podaci

Za ulazne podatke simulacije odabrane su cijene od Brent Crude Oil Spot što je, uz WTI Crude Oil, jedno od glavnih mjerila koja se koriste kod određivanja cijena nafte. Brent nafta izvorno dolazi iz istoimenog naftnog polja, no danas se kao pojam se odnosi na cijelokupno naftno tržište u morima sjevero-zapadne Europe.

Podaci su preuzeti sa službene web stranice američke federalne agencije [U.S Energy Information Administration](#) u CSV formatu te sadrže “dollars per barrel” cijene Brent nafte za svaki radni dan od

20.05.1987 do 13.06.2022. Zbog velike stagnacije prije i naglih fluktuacija tokom financijske krize 2008. za svrhe simulacije koristiti će se podskup cijena u razdoblju od 13.06.2012. do 13.06.2022.



## Konceptualni model

Cilj ovog simulacijskog modela je generiranje predviđanja cijene nafte uzevši u obzir kretanje cijena u prošlosti. Kao varijable za tu svrhu koristiti ćemo složenu godišnju stopu rasta i volatilnost cijene unutar jedne godine. Složena godišnja stopa rasta predstavlja povratnu stopu koja je potrebna da neka investicija od početne vrijednosti dosegne krajnju vrijednost u nekom vremenskom razdoblju (Fabozzi, Anson and Jones, 2013).

Definira se kao:

$$CAGR(t_0, t_n) = \left( \frac{V(t_n)}{V(t_0)} \right)^{\frac{1}{t_n - t_0}} - 1$$

gdje je  $V(t_0)$  početna vrijednost,  $V(t_n)$  konačna vrijednost, a  $t_n - t_0$  broj godina.

Godišnja volatilnost se dobiva umnoškom standardne devijacije dnevnih promjena i kvadratnog korijena radnih dana godine. Ove dvije varijable koristiti će se kao parametri pri generiranju dnevnih stopa povrata. Pošto distribucija dnevnih stopa stvarnih podataka prati normalnu razdiobu, pomoću nje će se generirati nove vrijednosti.

# Računalni model

Računalni model izrađen je u programskom jeziku Python uz pomoć *matplotlib*, *pandas* i *numpy* biblioteka. Podaci se učitavaju koristeći *pandas* funkciju *read\_csv* i pohranjuju u *dataframe* varijablu te se odabire raspon od 10 godina.

```
data = pd.read_csv(
    "Europe_Brent_Spot_Price_FOB.csv",
    skiprows=4,
    index_col=[0], parse_dates=[0])
# odabir vremenskog raspona i okretanje redoslijeda
prices = data.loc["06/13/2012":"06/13/2022"].iloc[::-1]
```

Zatim izračunavamo varijable koje će nam biti potrebne za generiranje nasumičnih vrijednosti.

```
postotak_rasta = prices.iloc[-1] / prices.iloc[1]

broj_godina = ((prices.index[-1] - prices.index[0]).days) /
365.0

cagr = value(postotak_rasta ** (1 / broj_godina) - 1)

trading_days = 252
std_dev = value(prices.pct_change().std()) * math.sqrt(trading_days)
```

Nakon što prikupimo potrebne varijable stvaramo jednu iteraciju, odnosno “Random Walk”, generiranja nasumičnih vrijednosti stopa povrata za jednu godinu uz pomoć funkcije za normalnu distribuciju iz *numpy* biblioteke.

```
dnevne_stope = np.random.normal(cagr/trading_days,
std_dev/math.sqrt(trading_days), trading_days)+1

price_series = [prices.iloc[-1]]

for i in dnevne_stope:
    price_series.append(price_series[-1] * i)
```

```
plt.plot(price_series,color="darkorange")
plt.title("Random Walk")
plt.show()
```

Time dobivamo:



Idući korak je ponavljanje simulacije 5000 puta. U svakoj iteraciji generiramo nove dnevne stope, te svaku od njih množimo s prošlom generiranom cijenom počevši od posljednje stvarne cijene. Svaka iteracija također stvara novu liniju koja se prikazuje na grafu.

```
closing_prices = []
broj_simulacija = 5000

for i in range(broj_simulacija):
    dnevne_stope = np.random.normal(
        cagr/trading_days,
        std_dev/math.sqrt(trading_days),
        trading_days) + 1

    price_series = [prices.iloc[-1]]
```

```


for j in dnevne_stope:
    price_series.append(price_series[-1] * j)

closing_prices.append(price_series[-1].values[0])

plt.plot(price_series)

plt.title(f"{broj_simulacija} simulations")
plt.show()

```



Ako uzmemo prosjek dobivenih vrijednosti možemo dobiti najvjerojatniju krajnju cijenu za iduću godinu, što nam daje rezultat od 130.48 dolara.

```
mean_end_price = round(np.mean(closing_prices), 2)
```

Kako bi lakše došli do zaključka o rezultatima simulacije grafički možemo usporediti generirane cijene.

```

# 10% najboljih ishoda
gornjih_10 = np.percentile(closing_prices, 100-10)

# 10% najgorih ishoda

```

```

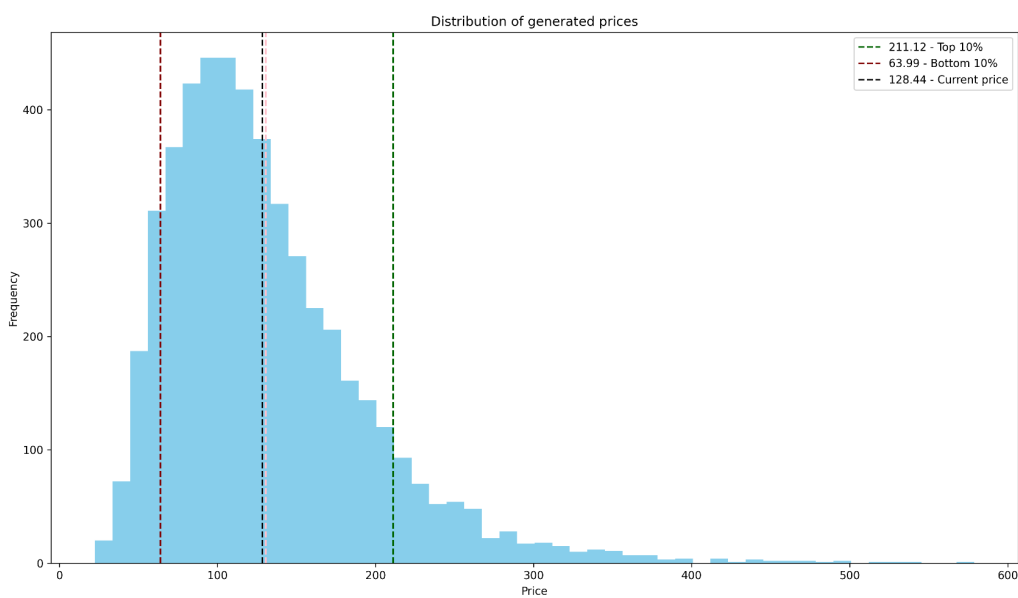
donjih_10 = np.percentile(closing_prices,10);

trenutna_cijena = value(prices.iloc[-1])

# histogram ukljucujuci najbolje i najgore ishode

plt.hist(closing_prices,color="skyblue",bins=50)
plt.axvline(gornjih_10,color="darkgreen",linestyle="dashed")
plt.axvline(donjih_10,color="maroon",linestyle="dashed")
plt.axvline(trenutna_cijena,color="black",linestyle="dashed")
plt.axvline(mean_end_price,color="pink",linestyle="dashed")

```



Distribucija cijena generiranih Monte Carlo simulacijom nam govori da bi se cijene nafte u idućih godinu dana trebale kretati ispod i u blizini trenutne cijene bez ekstremnih padova, ali s mogućim blažim porastima.

# Zaključak

Nasumičnim generiranjem brojki dobivamo okvirnu i neizvjesnu sliku budućih cijena nafte. Zbog raznih vanjskih utjecaja, korištenjem povijesnih promjena cijene nije moguće doći do preciznih predviđanja, ali ovakve simulacije, s puno većim brojem iteracija, mogu pomoći pri razumijevanju distribucija mogućih ishoda.

## Popis literature

- Čerić, V., 1993. *Simulacijsko modeliranje*. Zagreb: Školska knjiga.
- Fabozzi, F., Anson, M. and Jones, F., 2013. *The handbook of traditional and alternative investment vehicles*. Hoboken, N.J.: Wiley.